
박테리아 종 예측하기



Contents

- 1. 소개 및 변수
- 2. 코드
- 3. 모델 분석




1. 소개 및 변수

게놈 분석 기술 데이터를 이용해 10가지의 다른 박테리아종을 분류 하고 특정 값이 불연속적인 이유와 이 정보로 할 수 있는 작업은 무엇이 있는지 확인 해 봅니다.

오류율 결정 방법과 테스트 데이터가 훈련 데이터와 어떻게 다른지 결과를 봅니다.

변수

row_id - target 200000 - Streptococcus_pneumoniae 200001 - Enterococcus_hirae etc.



2. 코드 (모듈)



Numpy, Pandas, Matplotlib Scikit-learn

In [30]:	1 import numpy as np
	2 import pandas as pd
	3 import matplotlib.pyplot as plt
	4
	5 from math import factorial
	6
	7 from sklearn.decomposition import PCA
	8 from sklearn.preprocessing import StandardScaler, LabelEncode
	9 from sklearn.cluster import KMeans

```
200000 - Streptococcus_pneumoniae
200001 - Enterococcus_hirae
```

데이터 삽입

박테리아 이름을 숫자로 변경

((200000, 289), (100000, 287))

```
np.unique(train_df.AOTOG2C8)
Out [34]: array([-4.29153442e-05, -4.19153442e-05, -4.09153442e-05, -3.99153442e-05,
                -3.89153442e-05. -3.79153442e-05. -3.69153442e-05. -3.59153442e-05.
                -3.49153442e-05, -3.39153442e-05, -3.29153442e-05, -3.19153442e-05,
                -3.09153442e-05, -2.99153442e-05, -2.89153442e-05, -2.79153442e-05,
                -2.69153442e-05, -2.59153442e-05, -2.49153442e-05, -2.39153442e-05,
                -2.29153442e-05. -2.19153442e-05. -2.09153442e-05. -1.99153442e-05.
                -1.89153442e-05. -1.79153442e-05. -1.69153442e-05. -1.59153442e-05.
                -1.49153442e-05, -1.39153442e-05, -1.29153442e-05, -1.19153442e-05,
                -1.09153442e-05, -9.91534424e-06, -8.91534424e-06, -7.91534424e-06,
                -6.91534424e-06. -5.91534424e-06. -4.91534424e-06. -3.91534424e-06.
                -2.91534424e-06, -1.91534424e-06, -9.15344238e-07, 8.46557617e-08,
                 1.08465576e-06. 2.08465576e-06. 3.08465576e-06.
                                                                    4.08465576e-06.
                 5.08465576e-06, 6.08465576e-06,
                                                   7.08465576e-06.
                                                                    8.08465576e-06.
                 9.08465576e-06, 1.00846558e-05,
                                                   1.10846558e-05,
                                                                    1.20846558e-05,
                 1.30846558e-05. 1.40846558e-05.
                                                   1.50846558e-05.
                                                                    1.60846558e-05.
                 1.70846558e-05.
                                 1.80846558e-05.
                                                   1.90846558e-05.
                                                                    2.00846558e-05.
                 2.10846558e-05.
                                  2.20846558e-05.
                                                   2.30846558e-05.
                                                                    2.40846558e-05.
                 2.50846558e-05.
                                  2.60846558e-05.
                                                   2.70846558e-05.
                                                                    2.80846558e-05.
                 2.90846558e-05.
                                 3.00846558e-05.
                                                   3.10846558e-05.
                                                                    3.20846558e-05.
                 3.30846558e-05,
                                 3.40846558e-05,
                                                   3.50846558e-05,
                                                                    3.60846558e-05,
                 3.70846558e-05. 3.80846558e-05.
                                                   3.90846558e-05.
                                                                    4.00846558e-05.
                 4.10846558e-05. 4.20846558e-05.
                                                   4.30846558e-05.
                                                                    4.40846558e-05.
                 4.50846558e-05. 4.60846558e-05.
                                                   4.70846558e-05.
                                                                    4.80846558e-05.
                 4.90846558e-05.
                                  5.00846558e-05.
                                                   5.10846558e-05.
                                                                    5.20846558e-05.
                 5.30846558e-05.
                                  5.40846558e-05.
                                                   5.50846558e-05.
                                                                    5.60846558e-05.
                 5.70846558e-05,
                                  5.80846558e-05,
                                                   5.90846558e-05,
                                                                    6.00846558e-05,
                                  6.20846558e-05.
                 6.10846558e-05.
                                                   6.30846558e-05.
                                                                    6.40846558e-05.
                 6.50846558e-05.
                                  6.60846558e-05.
                                                   6.70846558e-05.
                                                                    6.80846558e-05.
                 6.90846558e-05.
                                  7.00846558e-05.
                                                   7.10846558e-05.
                                                                    7.20846558e-05.
                 7.30846558e-05.
                                 7.40846558e-05.
                                                   7.50846558e-05.
                                                                    7.60846558e-05.
                 7.70846558e-05.
                                 7.80846558e-05.
                                                   7.90846558e-05.
                                                                    8.00846558e-05.
                 8.20846558e-05.
                                  8.40846558e-05.
                                                   8.70846558e-05.
                                                                    9.70846558e-05.
                 1.07084656e-04, 1.17084656e-04,
                                                   1.27084656e-04.
                                                                    1.37084656e-04.
                 1.47084656e-04. 1.57084656e-04.
                                                   1.67084656e-04.
                                                                    1.77084656e-04.
                 1.97084656e-04. 9.57084656e-04.
                                                   9.95708466e-031)
```

In [34]:

중복된 요소 찾기

값의 불연속성이 확인이 됩니다.

값을 보니

부동 소수점 숫자이지만 고유 값이 200000개가 아니라 약 1000개 정도입니다. 마지막 몇 자리는 항상 동일하다는걸 알 수 있습니다.

(1.00846558e-05부터 9.70846558e-05까지 항상 0846558로 끝남)

부동 소수점 숫자 정수로 변경

Out[36]:		A0T0G0C10	A0T0G1C9	A0T0G2C8	A0T0G3C7	A0T0G4C6	A0T0G5C5	A0T0G6C4	A0T0G7C3	A0T0G8C2	A0T0G9C1	A8T0G0C2	A8T0G1C1	A8	
	134593	0	0	0	0	0	0	0	0	0	0	0	0		
	154979	0	0	7	19	33	41	33	13	3	0	247	517		
	7815	1	4	31	121	231	251	222	155	31	2	114	222		
	178351	2	7	103	611	1345	1718	1279	543	76	7	71	157		
	149758	0	0	10	20	0	30	10	10	0	0	450	1240		
	133151	0	0	0	0	0	0	0	0	0	0	0	0		
	122368	0	8	114	655	1473	1913	1465	626	87	10	90	155		
	153561	0	0	0	0	0	0	0	0	0	0	0	1000		
	52721	0	0	0	0	0	0	10	0	0	0	330	890		
	82559	0	20	60	110	170	270	160	140	0	0	60	190		
	10 rows	10 rows × 286 columns													
	4														


1, 10, 1000, 100000 최대 공약수 활용

```
In [37]:
             train_i.sum(axis=1).min(), train_i.sum(axis=1).max()
Out [37]:
         (1000000, 1000000)
In [38]:
              train_df['gcd'] = np.gcd.reduce(train_i[elements], axis=1)
              test_df['gcd'] = np.gcd.reduce(test_i[elements], axis=1)
              np.unique(train_df['gcd'], return_counts=True)
              np.unique(test_df['gcd'], return_counts=True)
Out [38]:
         (array([ 1, 10, 1000, 10000]),
          array([25208, 24951, 24930, 24911], dtype=int64))
```

1000000, 100000, 1000, 100 데카머를 넣고 머신러닝을합니다.

AoToGoC10에서 A1oToGoC0까지 286가지 유형이 모두 몇 번 발생하는지 계산합니다. 모든 카운트를 행 합으로 나누고 바이어스를 빼서 스펙트럼을 정규화합니다. 100으로 갈 수록 정보가 없고 예측이 어려운걸 볼 수 있습니다.

- gcd = 1의 경우 높은정확도 예측
- gcd=10000경우 낮은 정확도가 보입니다.




4개의 GCD 값에 대한 중복을 개별적으로 계산하면 대부분의 중복이 높은 GCD 값에 대해 발생한다는 것을 알 수 있습니다.


100개의 데카머가


1000000개의 데카머 286개의 빈에 들어가는 것보다 더 많은 중복을 예상합니다.




Duplicates in Training










가장 높은 정밀도(1000000 데카머)로 두 개의 임의의 특징을 구성합니다.

모든 클래스의 포인트가 8개의 클러스터로 그룹화되고 8개의 클러스터가 원점에서 교차한다는 것을 알 수 있습니다.



오류가 많을 수록 클러스터가 원점에 가까워지고 겹치기 시작합니다.

다음 히스토그램은 8개의 스케일링(8개의 오류율에 해당)이 있고 스케일링이 10개의 박테리아모두에 대해 동일함을 보여줍니다. 히스토그램에서 8개 값을 읽거나 1차원 k-means 클러스터링알고리즘 으로 결정할 수 있습니다. 축소된 7개의 클러스터는 크기가 550이고 내부에 중복이었습니다.

확장되지 않은 클러스터의 크기는 1100입니다(이 중 800은 고유하고 300은 중복)

```
In [44]:
          1 v = train_df[elements].abs().sum(axis=1)
          2 chosen_gcd = 1
          4 plt.figure(figsize=(18.14))
          5 plt.tight layout()
          6 for t in range(10) :
                 plt.subplot(5, 2, t+1)
                 plt.title(le.inverse_transform([t])[0])
          8
          9
                 vt = v[(train_df['gcd'] == chosen_gcd) & ( train_df['target_num'] == t)]
                 km = KMeans(n_clusters=8)
                 km.fit(vt.values.reshape(-1, 1))
         13
                 cluster_max = km.cluster_centers_.max()
         14
                 print(le.inverse_transform(np.array([t]))[0])
         15
                 print('Cluster centers:', sorted((km,cluster centers / cluster max),rayel(),round(2)))
                 print('Cluster sizes:', np.unique(km.predict(vt.values.reshape(-1, 1)), return counts=True)[1][np.argsort(km.cluster centers.
         16
                 print('Cluster unique elements:',
         18
                      train_df[elements][(train_df['gcd'] == chosen_gcd) & (train_df['target_num'] == t)].
         19
                      groupby(km.predict(vt.values.reshape(-1, 1))).apply(lambda df: np.unique(df.values, axis=0).shape[0]).values[np.argsort(l
                 print()
                 plt.hist(vt / cluster_max, bins=np.linspace(0, (vt / cluster_max),max(), 200), color='m', density=True)
                 plt.xticks(ticks=(km.cluster_centers_ / cluster_max).round(2))
         24
                 plt.xlabel('scale')
                 plt.vlabel('density')
         26 plt.subplots adjust(hspace=0.5)
         27 plt.show()
```

Bacteroides_fragilis

Cluster centers: [0.1, 0.24, 0.46, 0.64, 0.7, 0.88, 0.94, 1.0]

Cluster sizes: [556 576 559 557 568 528 585 1145]

Cluster unique elements: [556 576 559 557 568 528 585 824]

Enterococcus_hirae

Cluster centers: [0.09, 0.23, 0.46, 0.64, 0.7, 0.88, 0.94, 1.0]

Cluster sizes: [534 542 565 533 556 560 555 1111]

Cluster unique elements: [534 542 565 533 556 560 555 804]

scherichia_fergusonii

Cluster centers: [0.11, 0.24, 0.46, 0.64, 0.7, 0.88, 0.94, 1.0]

Cluster sizes: \[547 \ 559 \ 543 \ 542 \ 553 \ 545 \ 566 \ 1127 \]

Cluster unique elements: [547 559 543 542 553 545 566 796]

Salmonella_enterica

Cluster centers: [0.1, 0.23, 0.46, 0.64, 0.7, 0.88, 0.94, 1.0]

Cluster sizes: [534 574 562 539 558 554 552 1147]

Cluster unique elements: [534 574 562 539 558 554 552 823]

Streptococcus_pneumoniae

Cluster centers: [0.09, 0.23, 0.46, 0.64, 0.7, 0.88, 0.94, 1.0]

Cluster sizes: [548 563 580 585 543 548 568 1098]

Cluster unique elements: [548 563 580 585 543 548 568 792]

mpylobacter_jejuni

Cluster centers: [0.09, 0.23, 0.46, 0.64, 0.7, 0.88, 0.94, 1.0]

Cluster sizes: [550 542 538 578 566 560 565 1083]

Cluster unique elements: [550 542 538 578 566 560 565 789]

Escherichia_coli

Cluster centers: [0.11, 0.24, 0.46, 0.64, 0.7, 0.88, 0.94, 1.0]

Cluster sizes: [552 524 538 545 549 540 553 1095]

Cluster unique elements: [552 524 538 545 549 540 553 796]

Klebsiella_pneumoniae

Cluster centers: [0.09, 0.23, 0.46, 0.64, 0.7, 0.88, 0.94, 1.0]

Cluster sizes: [532 590 548 552 584 561 556 1109]

Cluster unique elements: $\lceil 532\ 590\ 548\ 552\ 584\ 561\ 556\ 808 \rceil$

Staphylococcus_aureus

Cluster centers: [0.09, 0.23, 0.46, 0.64, 0.7, 0.88, 0.94, 1.0]

Cluster sizes: [545 576 549 575 548 556 553 1101]


Cluster unique elements: [545 576 549 575 548 556 553 790]

Streptococcus_pyogenes

Cluster centers: [0.09, 0.23, 0.46, 0.64, 0.7, 0.88, 0.94, 1.0]

Cluster sizes: [558 558 546 583 550 511 556 1129]

Cluster unique elements: [558 558 546 583 550 511 556 808]



Data Visualization

Train, Test ∃ □

박테리아 DNA를 훈련을 시킨 결과 Test set의 박테리아는 다른 DNA를 갖는 결과가 나왔습니다.

